

Pruebas de Flujo Completo y Evaluación de Calidad de Datos

1. Introducción

Este documento presenta una combinación de pruebas de flujo completo del sistema (end-to-end) y una evaluación de calidad de los datos procesados por el sistema de análisis musical desarrollado a partir del Million Song Subset. Dado que el proyecto no será desplegado como una aplicación web o móvil, se optó por esta estrategia en lugar de realizar pruebas de integración tradicionales.

El objetivo principal es asegurar que los scripts desarrollados trabajen de forma coordinada y que los datos generados sean precisos, limpios y adecuados para análisis posteriores.

2. Pruebas de Flujo del Sistema

Estas pruebas verifican que cada componente del sistema funcione correctamente de principio a fin, desde la carga de archivos hasta la limpieza de los datos.

Descripción del Flujo General:

1. Explorar archivos `.h5`
2. Extraer metadatos clave (nombre del artista, canción, etc.)
3. Buscar canciones por nombre o artista
4. Limpiar y transformar los datos a un formato estructurado (CSV y HDF5)

Tabla de Pruebas:

Etapas	Script	Función Probada	Resultado Esperado	Resultado Obtenido
1	main.py	Recorrido por carpetas y detección de archivos `.h5`	Listado correcto de rutas y claves internas de los archivos HDF5	✅ Archivos encontrados y claves mostradas en consola
2	metadata.py	Extracción de metadatos clave (nombre de artista, título de	Impresión de los primeros 10 registros con datos	✅ Información correctamente extraída y decodificada

		canción)	legibles	
3	searchByName.py	Búsqueda por coincidencia parcial de nombre de artista o canción	Resultados que contengan el string de búsqueda (ej. "mendes")	✅ Se muestran coincidencias parciales como "Shawn Mendes"
4	dataCleansing.py	Lectura masiva, limpieza y exportación de datos	Se genera un archivo `.csv` limpio y utilizable	✅ Archivos `cleaned_music_data.h5` y `.csv` creados exitosamente sin errores

3. Evaluación de Calidad de Datos

📁 Archivo evaluado: cleaned_music_data.csv

🔍 Verificaciones realizadas:

Verificación	Método	Resultado
Valores nulos	df.isnull().sum()	Todos los campos vacíos fueron correctamente rellenados con la mediana (numéricos) o "Unknown" (textuales)
Duplicados	df.duplicated().sum()	No se encontraron duplicados en el DataFrame resultante
Tipos de datos	df.dtypes	Se confirmaron tipos adecuados: strings convertidos de byte a UTF-8, numéricos correctamente inferidos
Formato limpio	Exportación a `.csv`	Archivo final sin caracteres extraños, codificado correctamente para visualización

✅ Comentario Adicional:

La función `convert_byte_strings()` implementada fue clave para transformar datos

almacenados como `bytes` en strings legibles. Esto evitó errores en la exportación y mejoró la compatibilidad con herramientas como Excel o Power BI.

4. Conclusión

Las pruebas realizadas demuestran que el sistema está funcionando correctamente a nivel de scripts y lógica general. El flujo completo de uso está bien definido y probado, desde la detección de archivos hasta la producción de datos limpios y organizados.

Gracias a la limpieza y validación aplicadas, el conjunto final de datos está listo para ser utilizado en análisis de tendencias musicales, visualización de datos o incluso para alimentar modelos de recomendación musical en fases futuras.